词法分析
(2. 手写词法分析器)

魏恒峰

hfwei@nju.edu.cn

2021 年 11 月 09 日 (周二)

手写词法分析器

识别字符串 s 中符合**某种词法单元模式**的**所有词素**

```
if ab42>=3.14
    xyz :=2.99792458E8
else
   xyz:= 2.718
   abc := 1024
```

ws　if　else　id　integer　real　sci　relop　assign (:=)

识别字符串 s 中符合**某种词法单元模式**的**所有词素**

```
if ab42>=3.14
   xyz :=2.99792458E8
else
  xyz:= 2.718
  abc := 1024
```

ws　if　else　id　integer　real　sci　relop　assign　(:=)

识别字符串 s 中符合**某种词法单元模式**的**前缀词素**

识别字符串 s 中符合**某种词法单元模式**的**所有词素**

```
if ab42>=3.14
   xyz :=2.99792458E8
else
  xyz:= 2.718
  abc := 1024
```

ws　if　else　id　integer　real　sci　relop　assign　(:=)

识别字符串 s 中符合**某种词法单元模式**的**前缀词素**

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

分支: 先判断属于哪一类, 然后进入特定词法单元的前缀词素匹配流程

识别字符串 s 中符合**某种词法单元模式**的**前缀词素**

循环: 返回当前识别出来的词法单元与词素, 继续识别下一个前缀词素

识别字符串 s 中符合**某种词法单元模式**的**所有词素**

先: **ws** **if** **else** **id** **integer**

然后: **relop**

最后: **real** **sci**

留给大家: **assign** (:=)

```
4)     public int line = 1;
5)     private char peek = ' ';
6)     private Hashtable words = new Hashtable();
```

line: 行号, 用于调试

peek: **下一个向前看字符 (Lookahead)**

words: 从词素到词法单元**标识符或关键词**的映射表

```
words.put("if", if)
words.put("else", else)
```

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

ws: **blank** **tab** **newline**

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

ws: **blank tab newline**

```
12)     public Token scan() throws IOException {
13)         for( ; ; peek = (char)System.in.read() ) {
14)             if( peek == ' ' || peek == '\t' ) continue;
15)             else if( peek == '\n' ) line = line + 1;
16)             else break;
17)         }
```

识别空白部分, 并忽略之

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

ws: **blank** **tab** **newline**

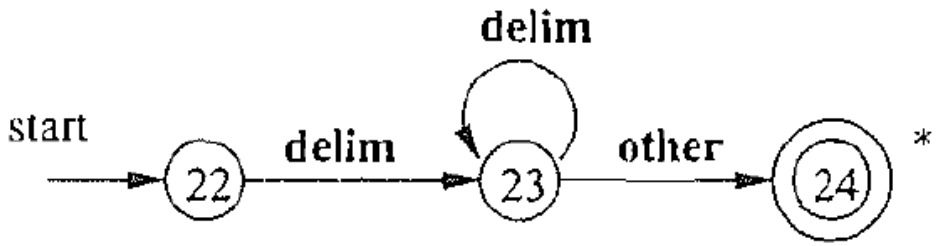

用于识别空白符的状态转移图

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

ws: **blank** **tab** **newline**

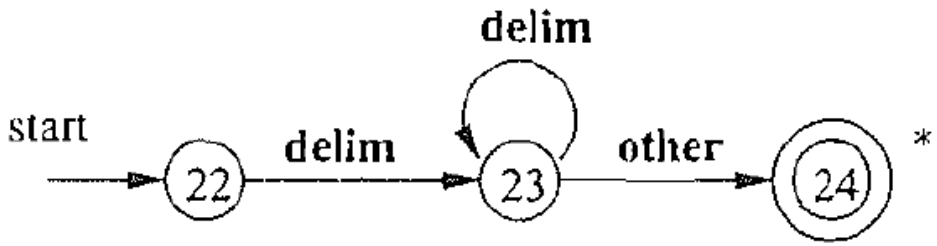

用于识别空白符的状态转移图

*: 识别出的空白符**不包含**当前 peek 指向的字符

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

ws: **blank** **tab** **newline**

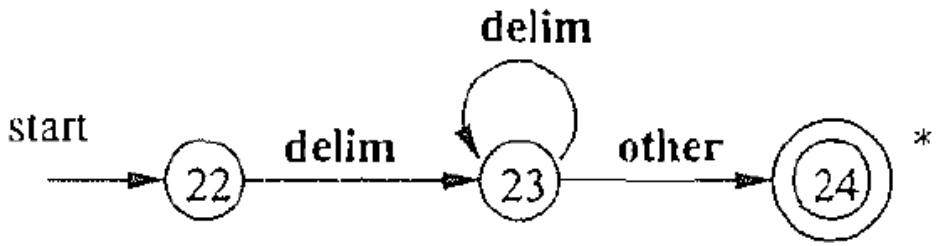

用于识别空白符的状态转移图

*: 识别出的空白符**不包含**当前 peek 指向的字符

22 : 碰到 other 怎么办?

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

integer: 整数 (简化处理, 允许以 0 开头)

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

integer: 整数 (简化处理, 允许以 0 开头)

```
18)         if( Character.isDigit(peek) ) {
19)             int v = 0;
20)             do {
21)                 v = 10*v + Character.digit(peek, 10);
22)                 peek = (char)System.in.read();
23)             } while( Character.isDigit(peek) );
24)             return new Num(v);
25)         }
```

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

integer: 整数 (简化处理, 允许以 0 开头)

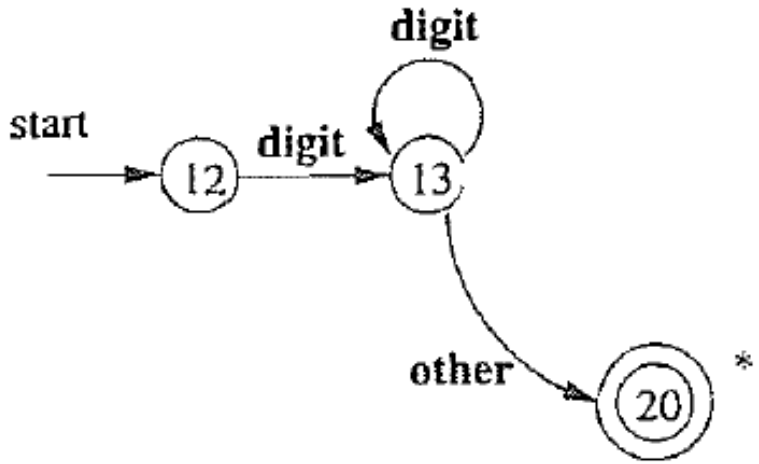

用于识别**integer**的状态转移图

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

integer: 整数 (简化处理, 允许以 0 开头)

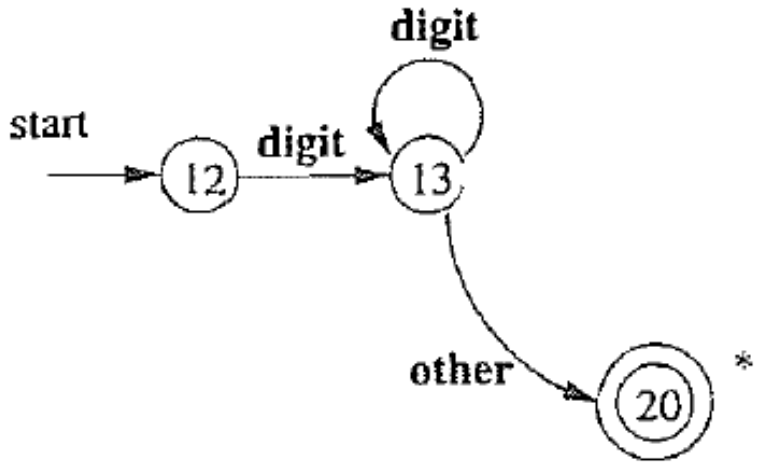

用于识别**integer**的状态转移图

12 : 碰到 `other` 怎么办?

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

id: 字母开头的字母/数字串

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

id: 字母开头的字母/数字串

```
26)         if( Character.isLetter(peek) ) {
27)             StringBuffer b = new StringBuffer();
28)             do {
29)                 b.append(peek);
30)                 peek = (char)System.in.read();
31)             } while( Character.isLetterOrDigit(peek) );
32)             String s = b.toString();
33)             Word w = (Word)words.get(s);
34)             if( w != null ) return w;
35)             w = new Word(Tag.ID, s);
36)             words.put(s, w);
37)             return w;
38)         }
```

识别词素、**判断是否是预留的关键字或已识别的标识符**、保存该标识符

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

id: 字母开头的字母/数字串

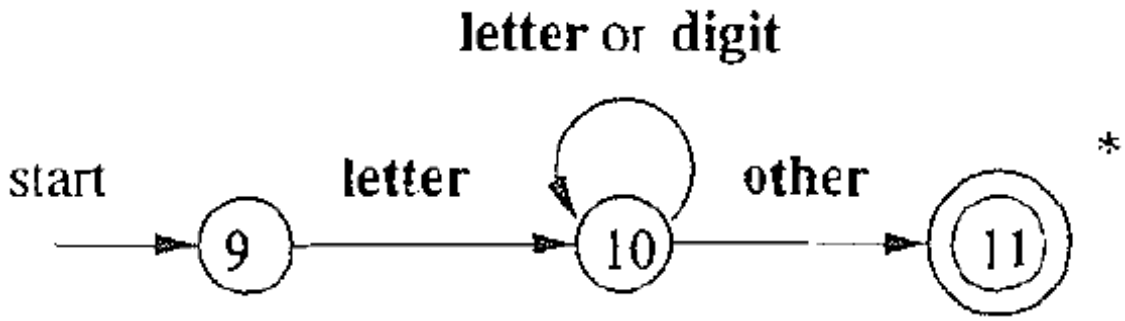

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

id: 字母开头的字母/数字串

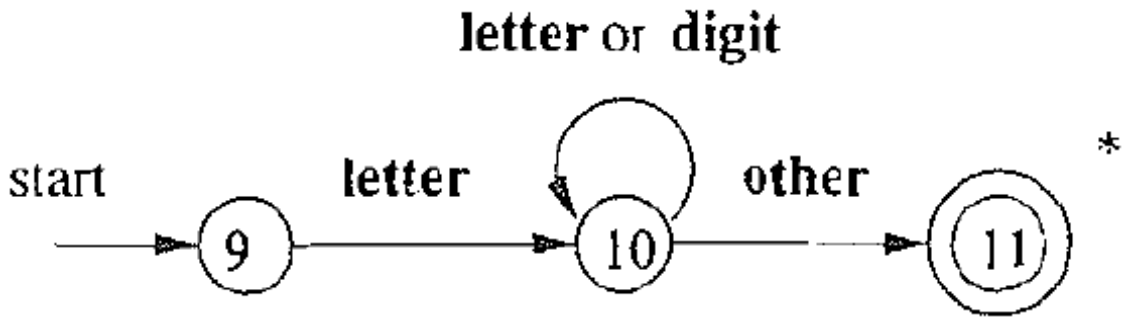

9：碰到 `other` 怎么办?

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

```
39)         Token t = new Token(peek);
40)         peek = ' ';
41)         return t;
```

错误处理模块: 出现**词法错误**, 直接报告异常字符

识别字符串 s 中符合**某种词法单元模式**的**前缀词素** (SCAN())

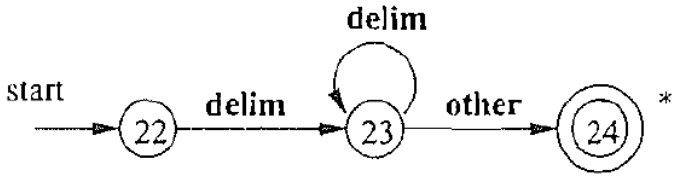

ws: 空白符

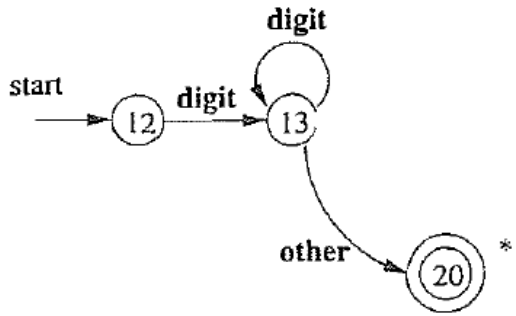

integer: 整数

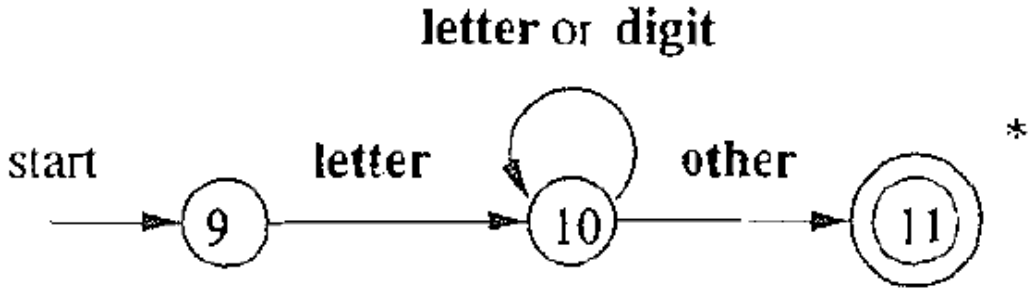

id: 标识符

```
39)         Token t = new Token(peek);
40)         peek = ' ';
41)         return t;
```

错误处理模块

识别字符串 s 中符合**某种词法单元模式**的**前缀词素** (SCAN())

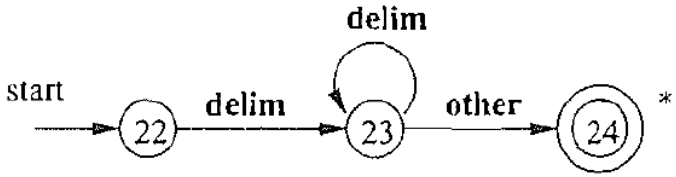

ws: 空白符

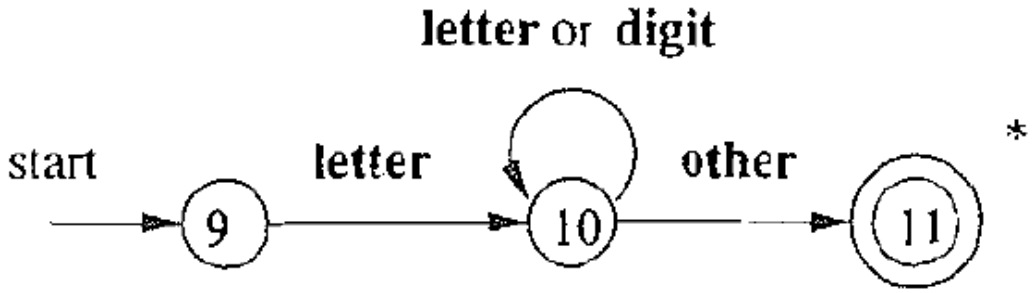

id: 标识符

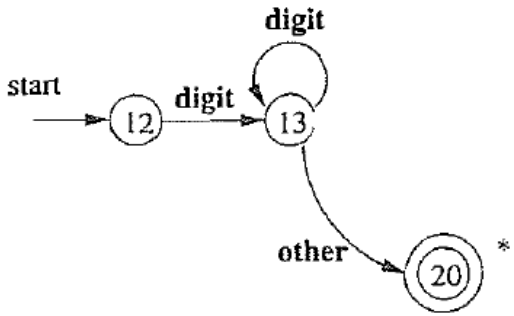

integer: 整数

```
39)     Token t = new Token(peek);
40)     peek = ' ';
41)     return t;
```

错误处理模块

关键点: 合并 22, 12, 9, 根据**下一个字符**即可判定词法单元的类型

否则, 调用错误处理模块 (对应 `other`), 报告**该字符有误**, 并忽略该字符

```
1)  package lexer;                          // 文件 Lexer.java
2)  import java.io.*; import java.util.*;
3)  public class Lexer {
4)      public int line = 1;
5)      private char peek = ' ';
6)      private Hashtable words = new Hashtable();
7)      void reserve(Word t) { words.put(t.lexeme, t); }
8)      public Lexer() {
9)          reserve( new Word(Tag.TRUE,  "true")  );
10)         reserve( new Word(Tag.FALSE, "false") );
11)     }
12)     public Token scan() throws IOException {
13)         for( ; ; peek = (char)System.in.read() ) {
14)             if( peek == ' ' || peek == '\t' ) continue;
15)             else if( peek == '\n' ) line = line + 1;
16)             else break;
17)         }
```

```
18)         if( Character.isDigit(peek) ) {
19)             int v = 0;
20)             do {
21)                 v = 10*v + Character.digit(peek, 10);
22)                 peek = (char)System.in.read();
23)             } while( Character.isDigit(peek) );
24)             return new Num(v);
25)         }
26)         if( Character.isLetter(peek) ) {
27)             StringBuffer b = new StringBuffer();
28)             do {
29)                 b.append(peek);
30)                 peek = (char)System.in.read();
31)             } while( Character.isLetterOrDigit(peek) );
32)             String s = b.toString();
33)             Word w = (Word)words.get(s);
34)             if( w != null ) return w;
35)             w = new Word(Tag.ID, s);
36)             words.put(s, w);
37)             return w;
38)         }
39)         Token t = new Token(peek);
40)         peek = ' ';
41)         return t;
42)     }
43) }
```

识别字符串 s 中符合**某种词法单元模式**的**所有词素**

外层**循环**调用 SCAN()

或者, 由语法分析器**按需**调用 SCAN()

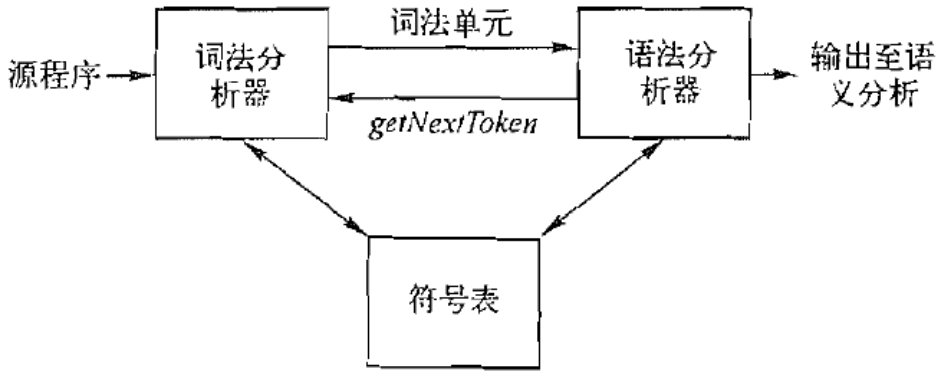

考虑例子 “123abc”

考虑例子 “123abc”

$$\langle \mathbf{num}, 123 \rangle \qquad \langle \mathbf{id}, abc \rangle$$

考虑例子 “123abc”

$\langle \mathbf{num}, 123 \rangle \qquad \langle \mathbf{id}, abc \rangle$

交给语法分析器报告语法错误

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

relop [1]: < > <= >= = <>

[1] 此处,= 是判断是否相等的关系运算符。请考虑, 如果 = 表示赋值, == 表示相等判断, 该如何设计词法分析器?

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

relop [1]: < > <= >= = <>

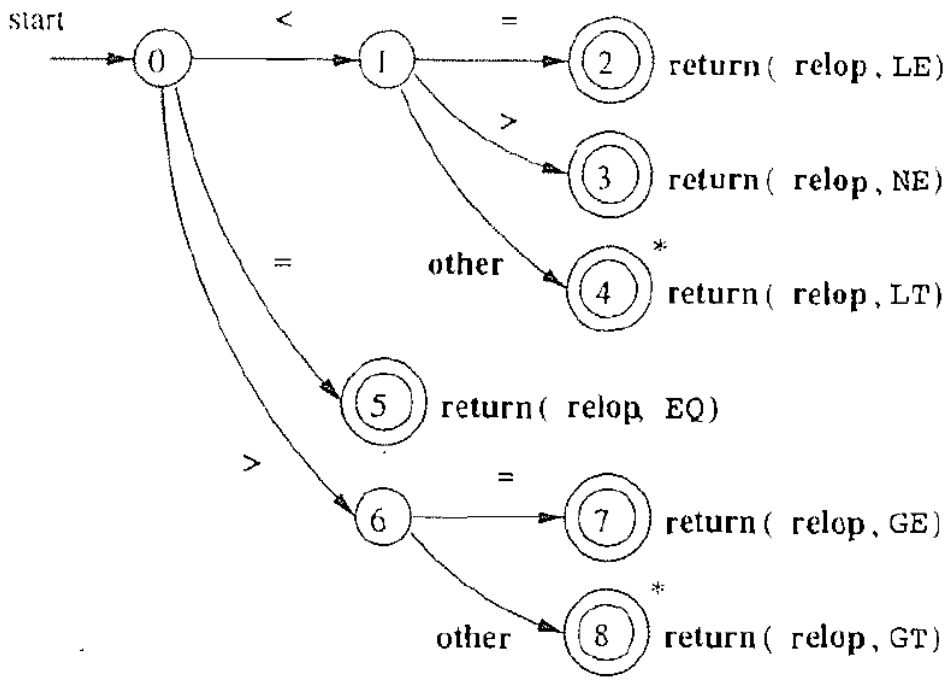

[1] 此处,= 是判断是否相等的关系运算符。请考虑, 如果 = 表示赋值, == 表示相等判断, 该如何设计词法分析器?

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

relop [1]: < > <= >= = <>

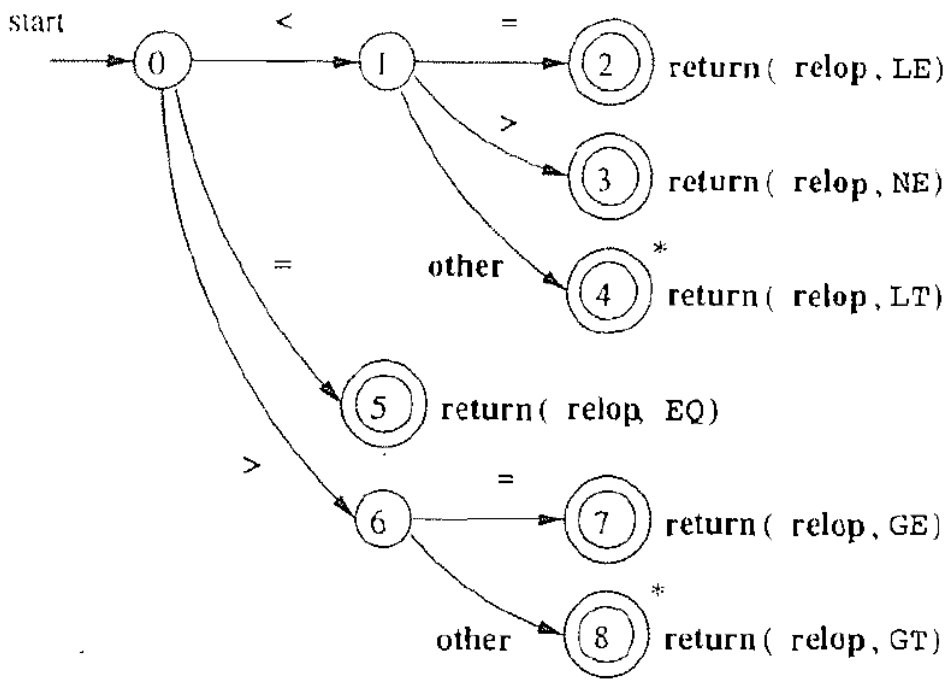

"最长优先原则": 例如, 识别出 <=, 而不是 < 与 =

[1] 此处,= 是判断是否相等的关系运算符。请考虑, 如果 = 表示赋值, == 表示相等判断, 该如何设计词法分析器?

识别字符串 s 中符合**特定词法单元模式**的**前缀词素**

relop [1]: < > <= >= = <>

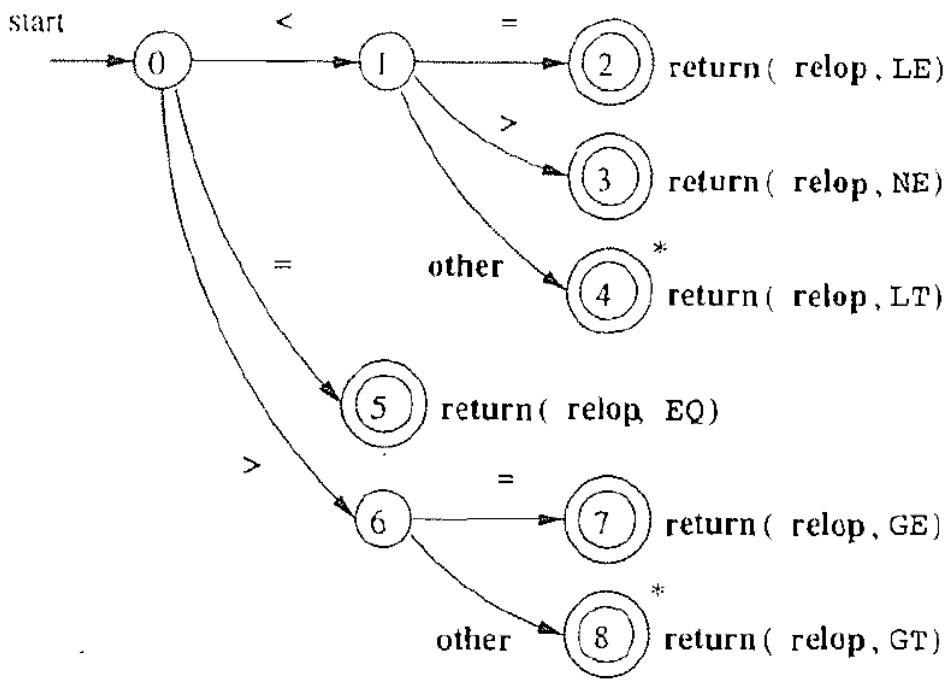

"最长优先原则": 例如, 识别出 <=, 而不是 < 与 =

0 : 碰到 other 怎么办?

[1] 此处,= 是判断是否相等的关系运算符。请考虑, 如果 = 表示赋值, == 表示相等判断, 该如何设计词法分析器?

识别字符串 s 中符合**某种词法单元模式**的**前缀词素** (SCAN())

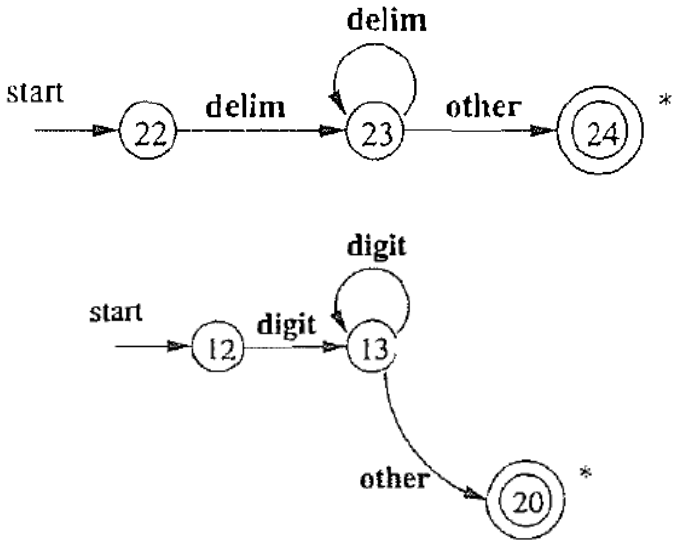

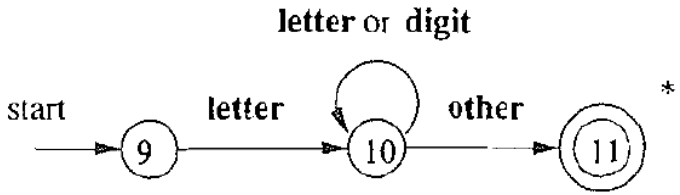

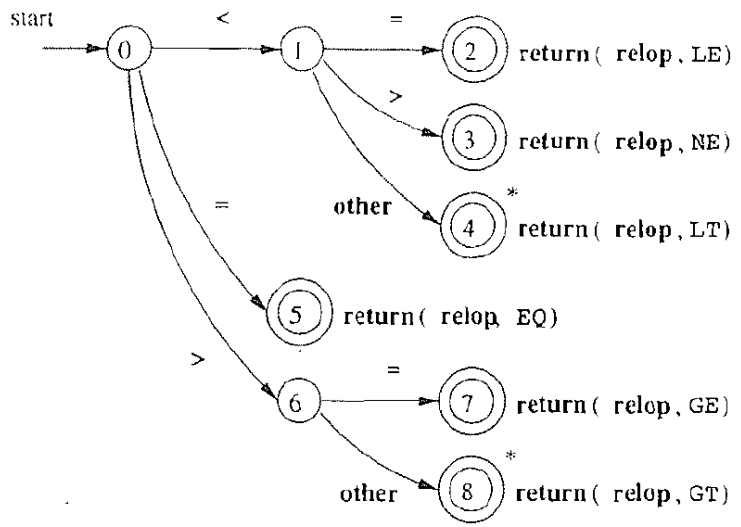


```
39)         Token t = new Token(peek);
40)         peek = ' ';
41)         return t;
```

识别字符串 s 中符合**某种词法单元模式**的**前缀词素** (SCAN())

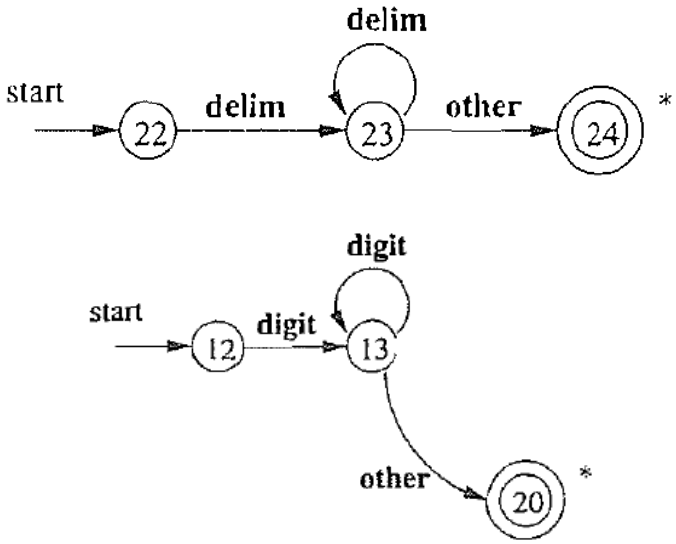

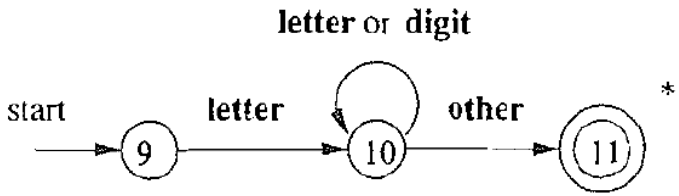

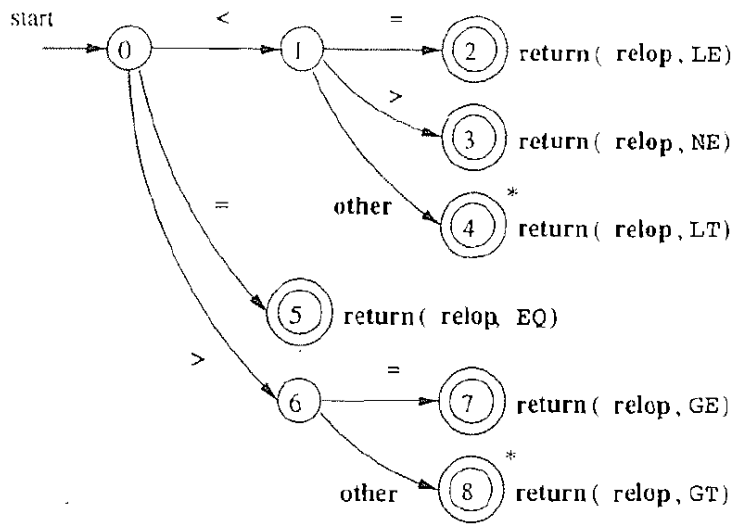


```
39)         Token t = new Token(peek);
40)         peek = ' ';
41)         return t;
```

关键点: 合并 $22, 12, 9, 0$, 根据**下一个字符**即可判定词法单元的类型

否则, 调用错误处理模块 (对应 `other`), 报告**该字符有误**, 并忽略该字符

但是, 词法分析器的设计并没有这么容易

ws　if　else　id　integer　relop

根据**下一个字符**即可判定词法单元的类型

每个状态转移图的每个状态要么是**接受状态**, 要么带有**other 边**

ws　if　else　id　integer　relop

根据**下一个字符**即可判定词法单元的类型

每个状态转移图的每个状态要么是**接受状态**, 要么带有**other 边**

如何同时识别 **integer**、**real** 与 **sci**?

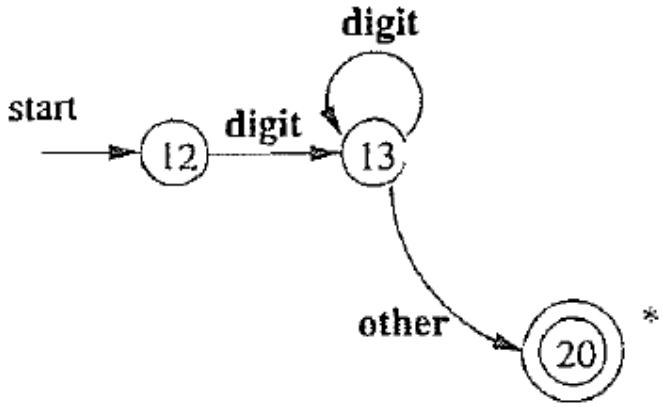

integer: 整数

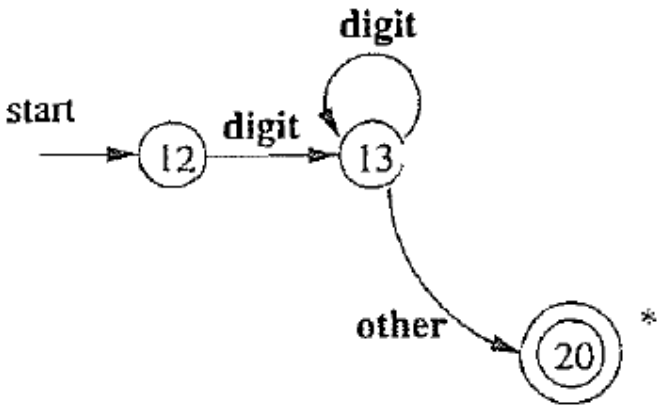

integer: 整数

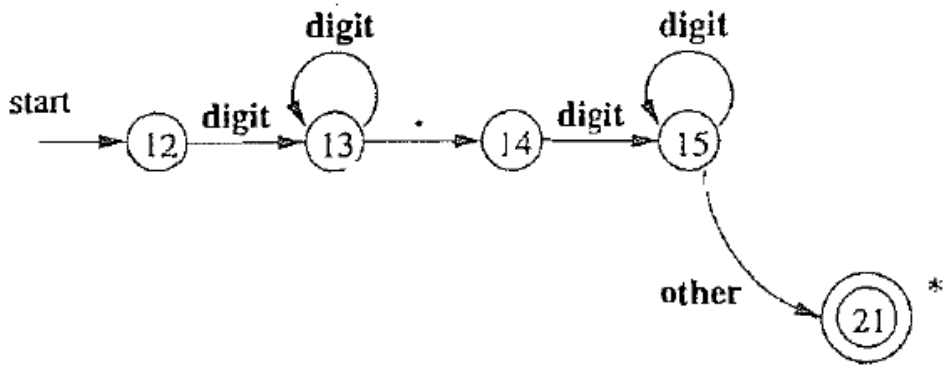

real: 浮点数 (无科学计数法)
(不识别 2.)

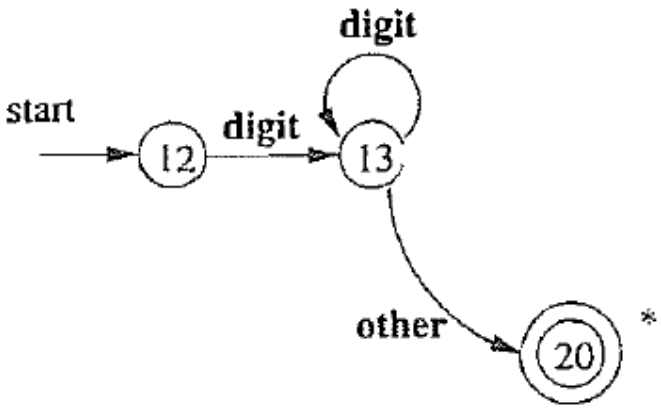

integer: 整数

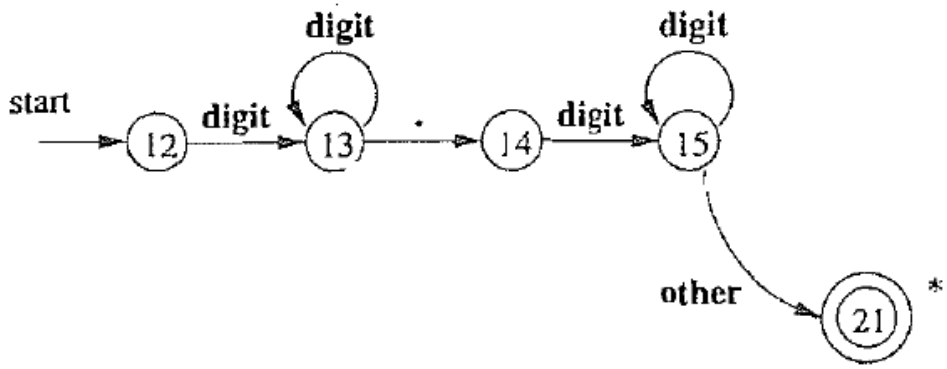

real: 浮点数 (无科学计数法)
(不识别 2.)

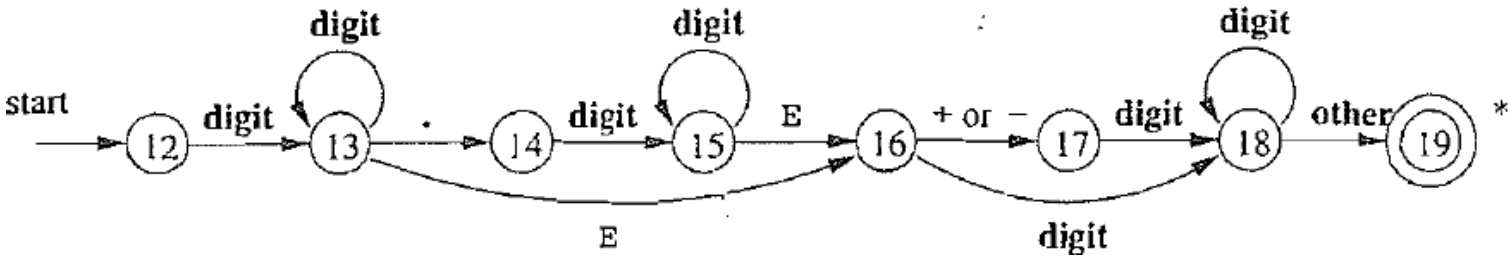

sci: 带科学计数法的浮点数
(2.99792458E8 3E8)

num: 整数部分[. 可选的小数部分][E[可选的 +-] 可选的指数部分]

num: 整数部分[. 可选的小数部分][E[可选的 +-] 可选的指数部分]

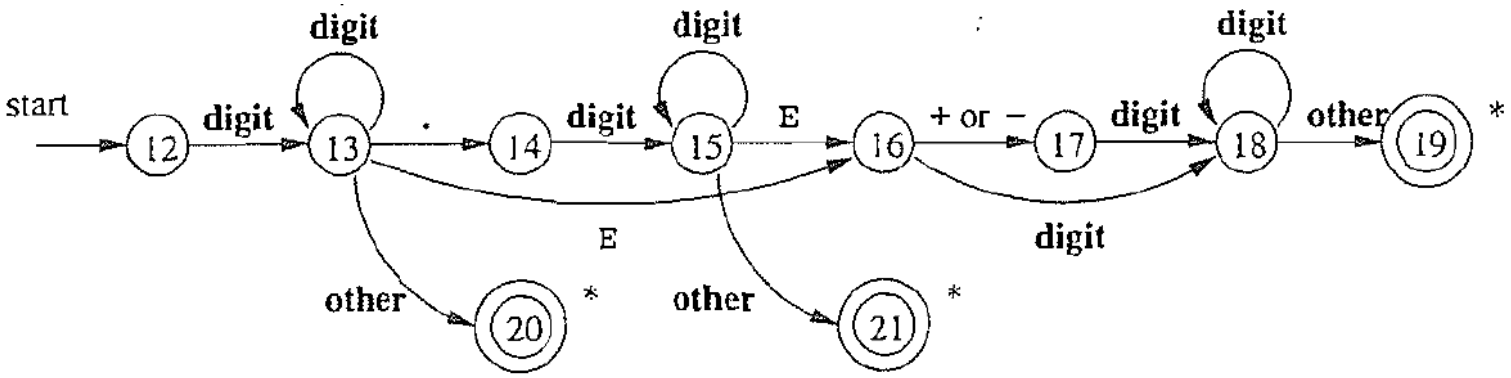

19, 20, 21：代表了不同的数字类型

num: 整数部分[. 可选的小数部分][E[可选的 +-] 可选的指数部分]

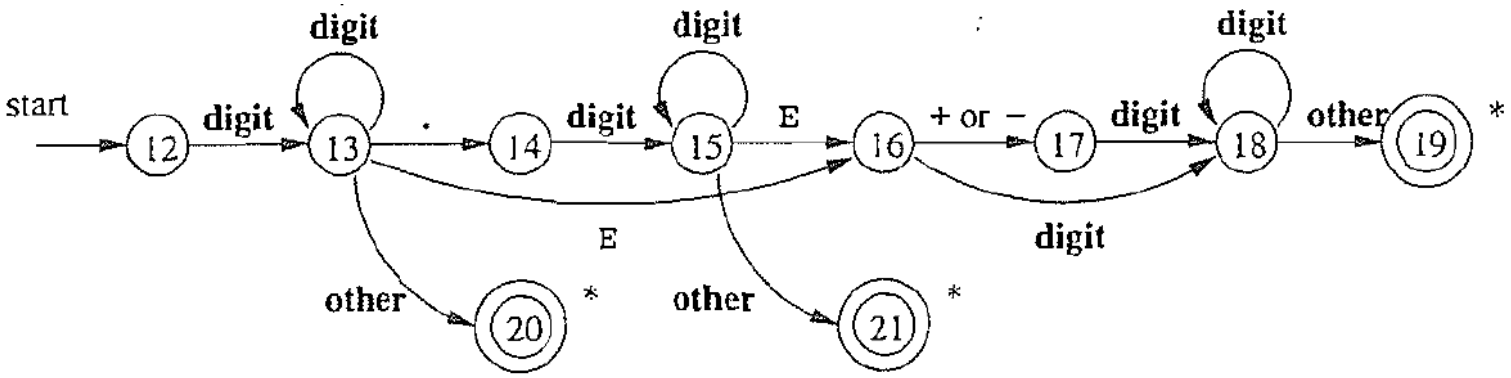

19, 20, 21：代表了不同的数字类型

12：碰到 `other` 怎么办?

num: 整数部分[. 可选的小数部分][E[可选的 +-] 可选的指数部分]

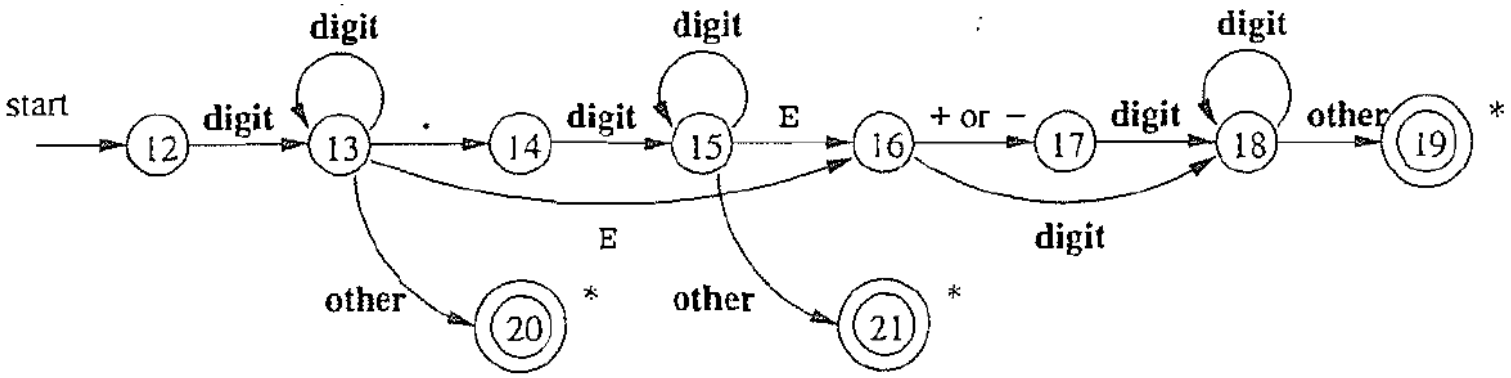

19, 20, 21：代表了不同的数字类型

12：碰到 `other` 怎么办? (尝试其它词法单元或进入错误处理模块)

num: 整数部分[. 可选的小数部分][E[可选的 +-] 可选的指数部分]

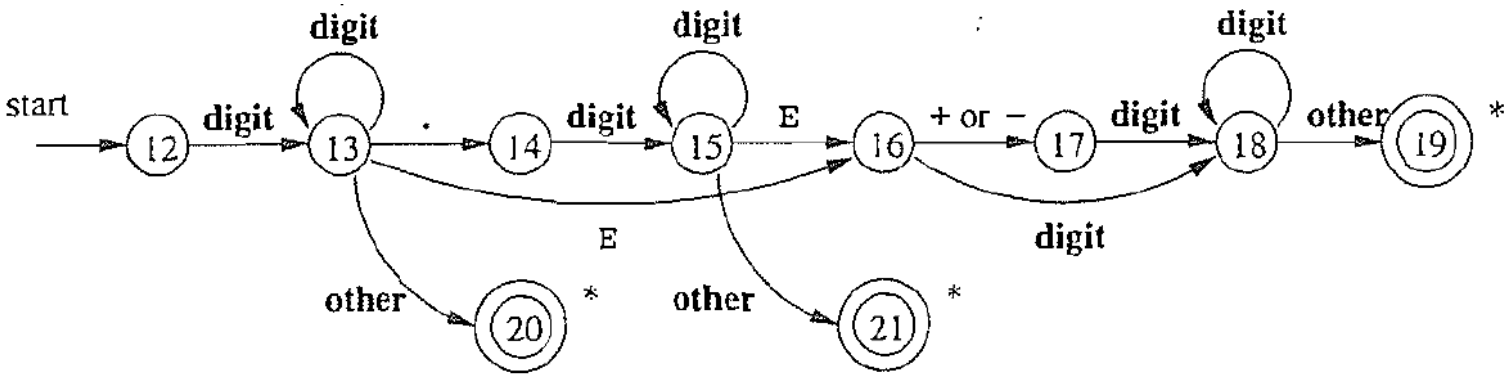

19, 20, 21 : 代表了不同的数字类型

12 : 碰到 other 怎么办? (尝试其它词法单元或进入错误处理模块)

14, 16, 17 : 碰到 other 怎么办?

num: 整数部分[. 可选的小数部分][E[可选的 +-] 可选的指数部分]

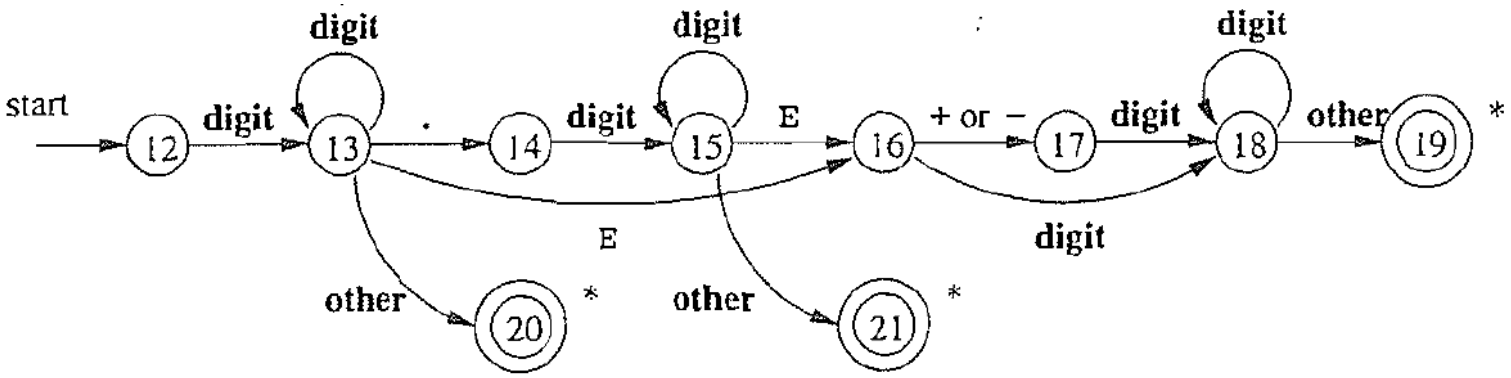

19, 20, 21 : 代表了不同的数字类型

12 : 碰到 other 怎么办? (尝试其它词法单元或进入错误处理模块)

14, 16, 17 : 碰到 other 怎么办? (回退, 寻找**最长匹配**)

识别字符串 s 中符合**某种词法单元模式**的**前缀词素** (SCAN())

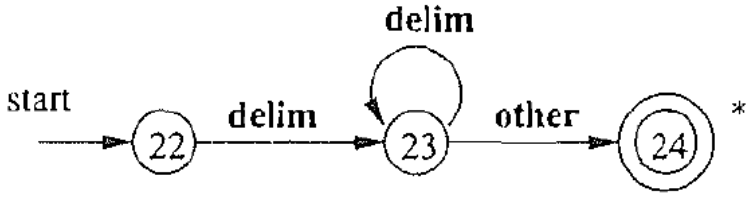

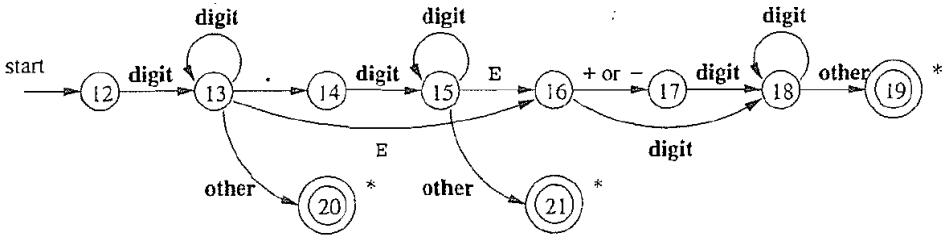

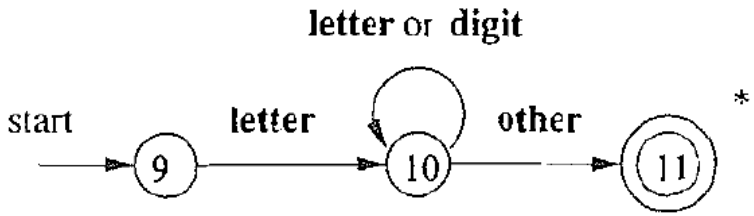

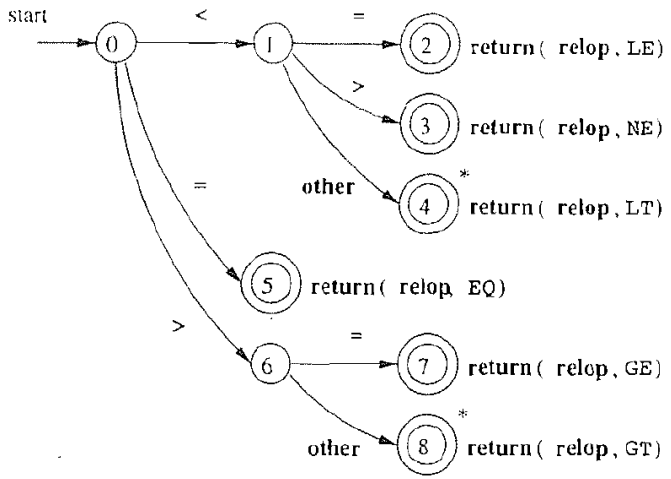


```
39)     Token t = new Token(peek);
40)     peek = ' ';
41)     return t;
```

识别字符串 s 中符合**某种词法单元模式**的**前缀词素** (SCAN())

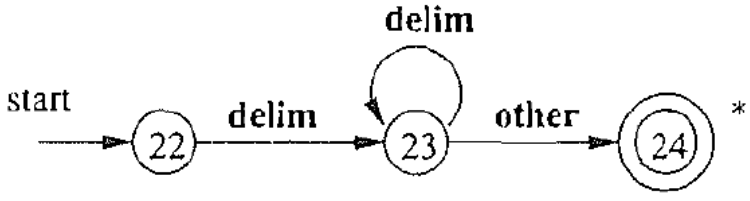

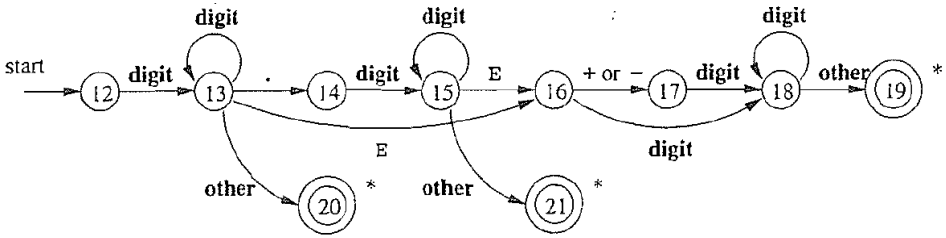

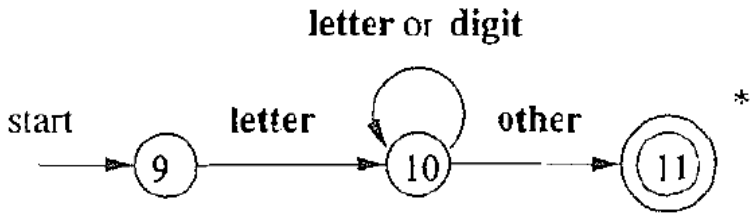

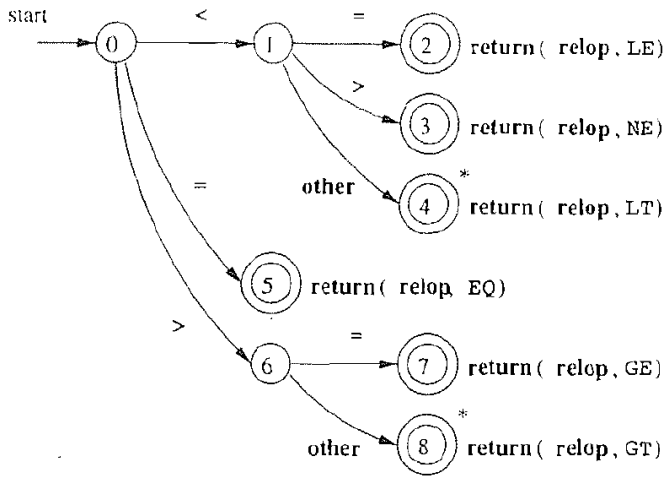


```
39)     Token t = new Token(peek);
40)     peek = ' ';
41)     return t;
```

关键点: 合并 22, 12, 9, 0, 根据**下一个字符**即可判定词法单元的类型

否则, 调用错误处理模块 (对应 other), 报告**该字符有误**, 忽略该字符。

注意, 在**sci**中, 有时需要**回退**, 寻找最长匹配。

3）有一个更好的方法，也是我们将在下面各节中采用的方法，就是将所有的状态转换图合并为一个图。我们允许合并后的状态转换图尽量读取输入，直到不存在下一个状态为止；然后像上面的 2 中讨论的那样取最长的和某个模式匹配的最长词素。

1.2345E+a

3）有一个更好的方法，也是我们将在下面各节中采用的方法，就是将所有的状态转换图合并为一个图。我们允许合并后的状态转换图尽量读取输入，直到不存在下一个状态为止；然后像上面的 2 中讨论的那样取最长的和某个模式匹配的最长词素。

1.2345E+a

1.2345 E + a


Thank
You!

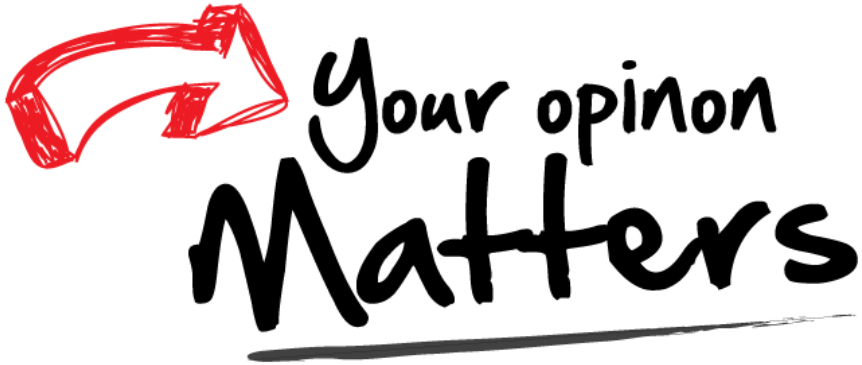

Office 926

hfwei@nju.edu.cn